

Université Sorbonne Paris Nord

Rapport de Projet

ETICS

Détection de la toxicité dans les contrats bancaires

Master 2 — EID2

Étudiants :

BENAMARA Amine
BENSALEM Tesnime
CHARAF Hassan
CHERKI Omar
PARAKARAN Vidur
SANTHALINGAM Mathura

Encadrant : **M.BOUFARES Faouzi**

Année universitaire :
2026–2027

1. Introduction

1.1 Contexte

Le projet ETICS s'inscrit dans la thématique Data for Ethics : mesurer, caractériser et détecter la toxicité dans des documents textuels. Nous nous concentrons sur les contrats de la vie quotidienne conclus avec une banque, un assureur, un bailleur, un employeur, un fournisseur d'énergie ou encore un opérateur téléphonique.

Ces contrats sont souvent parfaitement légaux, mais ils soulèvent néanmoins plusieurs questions éthiques. Le sujet en identifie six principales : l'équilibre entre les parties, la transparence, la justice et l'équité, la protection des personnes vulnérables, l'usage des données personnelles et la discrimination. Ainsi, un contrat peut respecter la législation en vigueur tout en présentant un déséquilibre important entre les parties ou en exploitant un manque de transparence.

1.2 Objectif de la partie 1

Avant de pouvoir évaluer un contrat sur le plan éthique, il est nécessaire de pouvoir le lire et l'exploiter automatiquement. Un fichier PDF constitue en effet une donnée peu structurée : il contient du texte mis en page, mais ne fournit pas nécessairement de manière explicite les notions d'article, de clause ou de thème.

L'objectif de cette première partie est donc de construire une base de données structurée à partir de ces documents afin de rendre leur contenu exploitable pour les étapes ultérieures du projet.

Ce rapport couvre trois aspects principaux :

- les données en entrée, notamment les fichiers traités, les différents types de contrats et les exemplaires disponibles ;
- l'architecture de la base de données ainsi que la description de ses différentes tables ;
- les problèmes rencontrés, aussi bien dans les documents sources que lors de leur intégration dans la base de données.

L'analyse de la toxicité à l'aide d'un modèle de langage (LLM), qui constitue la deuxième partie du projet, n'est abordée ici qu'en perspective.

2. Vue d'ensemble du projet

Le schéma ci-dessous décrit le projet comme une transformation progressive des données non structurées en données structurées. La première partie du projet couvre ainsi toute la moitié Data Engineering, depuis la lecture et l'extraction des informations contenues dans les fichiers jusqu'à leur stockage dans une base de données relationnelle.

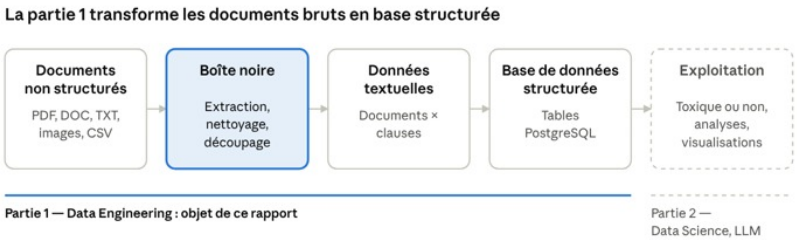


Figure 1: Chaîne du projet ETICS

La boîte noire représentée dans le schéma correspond au pipeline que nous avons construit et qui est présenté en détail dans la section. Ce pipeline assure la transformation des documents sources en données structurées. Il produit notamment un tableau reliant les documents aux différentes clauses qu'ils contiennent, lequel est ensuite chargé dans la base de données décrite dans la section.

La décision finale visant à déterminer si une clause ou un contrat est toxique, ainsi que les différentes analyses associées, ne font pas partie de cette première étape. Elles relèvent de la partie 2 du projet, consacrée à l'analyse à l'aide de modèles de langage (LLM).

3. Données en entrée

Type de documents. Nous travaillons sur des « contrats de la vie quotidienne » du secteur bancaire : textes juridiques longs, imposés au client (contrats d'adhésion) et le plus souvent au format PDF. Nous avons rassemblé une vingtaine de PDF, de trois natures différentes :

Nature	**Exemple dans notre corpus**	**Intérêt pour l'étude**
Convention de compte	Conditions générales des comptes particuliers (réf. 13.03.01, 09/24, 19 pages)	Équilibre entre les parties, résiliation, preuve, données personnelles
Contrat carte bancaire	Fonctionnement des cartes bancaires & services associés, Caisse d'Epargne Grand Est Europe (en vigueur au 15/05/2022, 20 pages)	Responsabilité du porteur, décisions automatisées, modification unilatérale

Grille tarifaire	Conditions tarifaires 2025 Particuliers, Banque Transatlantique	Transparence des prix, frais d'incident, mentions « nous consulter »

Nous avons aussi un fascicule de conditions générales de banque à distance (2026) et d'autres conventions de compte.

Exemples de clauses repérées à la lecture *(candidates à examen, pas des verdicts) :*

Document / article	**Clause (résumé)**	**Critère éthique concerné**
Convention de compte, art. 2.5 (p. 3)	La banque peut compenser les soldes entre comptes sans prévenir le client, mais aucune faute ne peut lui être reprochée si elle ne le fait pas	Équilibre entre les parties
Convention de compte, art. 2.3.1 (p. 3)	Les opérations sont présumées ratifiées après 1 mois sans contestation, alors que le délai est de 13 mois pour les opérations de paiement (art. 2.3.2)	Transparence, cohérence
Convention de compte, art. 8.3 (p. 12)	Les variations du taux de change s'appliquent immédiatement et sans préavis	Équilibre, transparence
Convention de compte, art. 10 (p. 19)	Toute modification est réputée acceptée en l'absence de contestation écrite sous 2 mois	Consentement libre
Convention de compte, art. 6.4.1 (p. 10)	Résiliation unilatérale possible pour « incivilité », notion non définie	Protection des personnes vulnérables, flou
Convention de compte, art. 9.5.2 et 9.5.3 (p. 16–17)	Partage des données avec le groupe et des partenaires, modèles de notation, sous-traitance au Maroc ou en Tunisie	Utilisation des données personnelles
Contrat carte, art. 11.4 (p. 11)	Pertes à la charge du titulaire sans limite en cas de « négligence grave »	Équilibre des parties
Contrat carte, art. 17.1 (p. 13)	Décision automatisée pouvant refuser une opération	Discrimination, transparence algorithmique
Grille tarifaire (p. 3–10)	Commission d'intervention de 8 € par opération (plafond 80 €/mois), tenue de compte de 15 à 100 €/mois, nombreux « Nous consulter »	Transparence des prix

4. Architecture de la base de données

Nous avons réalisé le schéma relationnel (MCD). Il est composé de cinq entités principales :

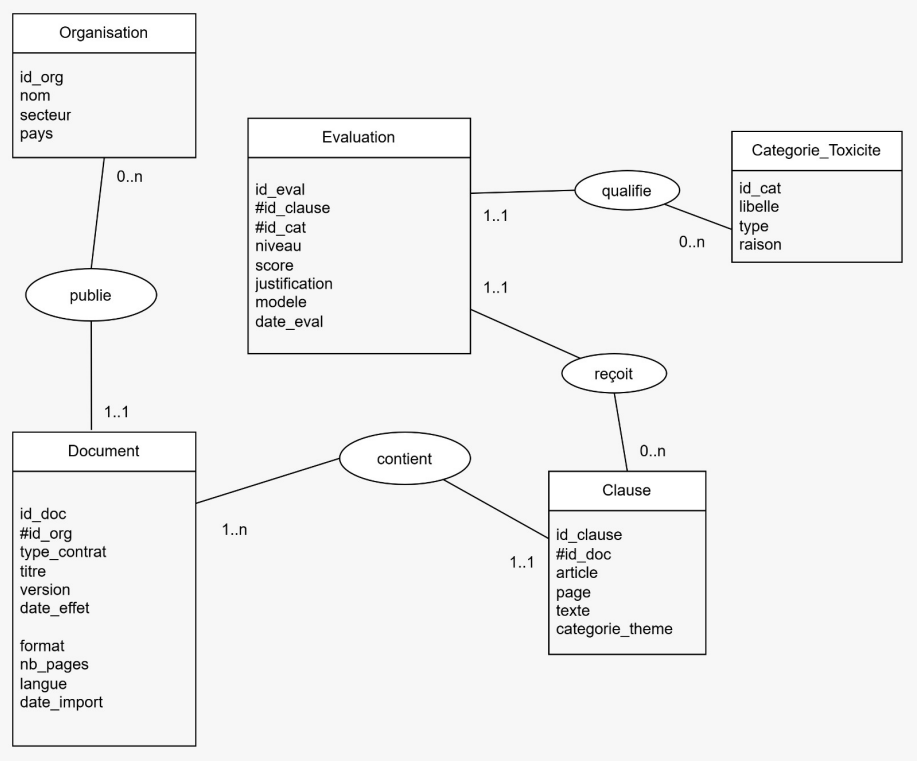


Figure 2: Modèle conceptuel de données (MCD) du projet ETICS

- **Organisation** (`id_org`, `nom`, `secteur`, `pays`) publie un ou plusieurs documents.
- **Document** (`id_doc`, `#id_org`, `type_contrat`, `titre`, `version`, `date_effet`, `format`, `nb_pages`, `langue`, `date_import`) contient un ou plusieurs clauses.
- **Clause** (`id_clause`, `#id_doc`, `article`, `page`, `texte`, `categorie_theme`) reçoit une ou plusieurs évaluations.
- **Évaluation** (`id_eval`, `#id_clause`, `#id_cat`, `niveau`, `score`, `justification`, `modèle`, `date_eval`) est qualifiée par une catégorie de toxicité.
- **Catégorie_Toxicité** (`id_cat`, `libellé`, `type`, `raison`) correspond aux

différents critères éthiques définis dans le sujet.

L'organisation des données permet ainsi de représenter les différentes étapes du traitement : une organisation publie des documents, chaque document est découpé en clauses, et chaque clause peut ensuite faire l'objet d'une ou plusieurs évaluations.

L'objectif de cette architecture est de transformer les données initialement non structurées, principalement issues de fichiers PDF, en données structurées et interrogeables. Cette structuration permet notamment de conserver le lien entre une clause, le document dont elle est issue, l'organisation concernée et les évaluations qui lui sont associées.

La base constitue ainsi le lien entre la phase de traitement des documents et la phase d'analyse de toxicité présentée dans la suite du projet.

5. Problèmes anticipés

5.1 Définir et mesurer la toxicité

Il n'existe pas de définition consensuelle de la « toxicité contractuelle ». Nous retenons les critères du sujet : équilibre entre les parties, clarté et transparence, justice et équité, protection des personnes vulnérables, utilisation des données personnelles, risques de discrimination. Cela soulève trois difficultés :

- **Légal ou éthique.** Une clause peut être parfaitement légale et critiquable éthiquement (par exemple le consentement par silence à une modification de contrat). Le modèle doit évaluer le déséquilibre, pas la conformité juridique. Le prompt et la grille d'annotation doivent le préciser.
- **Subjectivité.** Deux annotateurs peuvent diverger. Il faudra mesurer l'accord inter-annotateurs (kappa de Cohen).
- **Dépendance au contexte.** Une clause isolée peut sembler abusive alors qu'elle est compensée ailleurs (le délai de 1 mois contre 13 mois, par exemple), et le sens dépend parfois de renvois entre articles.

5.2 Extraction et découpage du texte

- **Mise en page.** Le contrat carte est en deux colonnes, la grille tarifaire contient des tableaux, et chaque page comporte des en-têtes et pieds de page répétés. Une extraction naïve mélange les colonnes et pollue le texte.
- **Bruit.** Nos PDF contiennent des coquilles (pagination « 20 sur 19 », phrases dupliquées à l'art. 3.3 de la convention de compte). Il faudra nettoyer sans altérer le sens.
- **Segmentation en clauses.** Le découpage par article (numérotation 2.3.1, 3.4.2.5, etc.) est faisable par expressions régulières, mais les articles très

longs (le 9.2 sur la signature électronique, par exemple) devront peut-être être sous-découpés.

- **Hétérogénéité.** Convention, contrat carte et grille tarifaire n'ont pas la même structure, donc pas le même découpage.
- **Limites des LLM.** Hallucinations, non-déterminisme, coût, longueur de contexte. Une sortie JSON imposée et une température basse sont nécessaires.

Pipeline envisagé : PDF → extraction avec détection de colonnes (PyMuPDF ou pdfplumber) → nettoyage → segmentation par article → LLM (sortie JSON : catégorie, niveau, score, justification) → insertion en base → agrégation par document.

6. Comment évaluer la toxicité de nos documents

6.1 Classification : comparaison avec le Golden Dataset

Un échantillon de clauses est annoté à la main (idéalement par au moins deux personnes), puis le LLM traite l'échantillon de test. On compare ses prédictions avec le Golden Dataset à l'aide de :

- **la matrice de confusion**, qui montre si le modèle sur-détecte (faux positifs) ou sous-détecte (faux négatifs) les clauses toxiques ;
- **la précision, le rappel et le F1-score.** Dans une logique « Data for Ethics », nous privilégions le rappel : il vaut mieux qu'un contrat légal lève une alerte (faux positif) que de rater une clause réellement abusive visant une personne peu instruite (faux négatif).

6.2 Évaluation qualitative de la justification générée

- **LLM-as-a-Judge.** Un second modèle, configuré pour l'évaluation, reçoit la clause, la justification de l'agent et une grille de notation. Il évalue sur une échelle de 1 à 5 si l'argumentaire démontre bien un problème (consentement libre, respect de la vie privée, etc.).
- **Contrôle d'ancrage (groundedness).** On vérifie que la justification s'appuie explicitement sur des termes présents dans le texte de la clause, pour détecter les hallucinations. C'est le principe de pertinence de l'approche RAG.
- **Human-in-the-Loop (HITL).** Des audits manuels réguliers sur un échantillon aléatoire valident que le raisonnement de l'IA correspond à la définition d'un contrat éthiquement satisfaisant.

7. Prochaines étapes

1. Corriger le MCD (section 2) et le transformer en schéma SQL.
2. Rédiger la grille d'annotation (définition des niveaux 0 à 3 par critère).
3. Prototyper l'extraction et le découpage sur 2 ou 3 documents types (un par nature).
4. Constituer un premier Golden Dataset d'une centaine de clauses.
5. Tester un premier prompt de classification et calculer les métriques.